

300 ЛЕТ СПбГУ

PestCLEF: извлечение графа знаний

Кубякин Никита · Зайнуллин Мансур · Аникин Роман

СПбГУ ·4-й курс ·23.Б16-пу ·Базы данных и распределённая цифровая платформа



Условная иллюстрация

В ОДНОМ СООБЩЕНИИ — НЕСКОЛЬКО СВЯЗЕЙ

«Оливковые деревья заражены Xylella в Monopoli».

В сообщении связаны возбудитель, растение и место.

Перевод фрагмента · документ 97985, [288,331).

Извлекаем связи и сохраняем документ-источник.

По нему возвращаемся к исходному тексту.

Качество извлечения нужно проверять.

Задача: текст → отношения

На входе английский текст о вредителях растений. Ответ состоит из троек «субъект, предикат, объект». Например, ToBRFV → Found_on → tomatoes: возбудитель обнаружен на растении.

Корпус:110 train +55 dev с разметкой;82 test без открытого эталона. Локально используем 165 размеченных документов.

CSV содержит doc_id и knowledge_graph. Для каждого id нужен JSON-массив троек со строковыми subject, predicate, object. Если связей не выбрано, записывается []. Это не утверждение об отсутствии фактов в тексте.

Источник: корпус; notebook, яч.9,34.

Тип	Смысл в задаче
Pest	вредитель или возбудитель
Plant	растение-хозяин
Disease	заболевание
Vector	организм-переносчик
Location	место
Date	дата или период
Dissemination_ pathway	путь распространения

В разметке субъект и объект могут иметь несколько эквивалентных названий; прогноз использует одну строковую форму. Граф относится к конкретному документу.

Упоминание, концепт и граф

Упоминание: фрагмент текста с типом и границами. Полное название вируса и ToBRFV встречаются в одном документе.

Сущность: объект, который обозначает текст. Концепт в нашем коде: группа упоминаний, считающихся одной сущностью документа. Каноническая форма служит подписью.

Граф знаний в определении книги: граф данных, потенциально дополненный схемой, идентичностью, контекстом, онтологиями или правилами. Реализация всех этих средств не обязательна.

Источник: гл.3 с.25; §6.2 с.107–108 (PDF45,127–128).

Pest: ToBRFV → Found_on → Plant: tomatoes

Узлы представляют концепты; предикат подписывает направленное ребро. Перестановка концов меняет смысл.

В NetworkX используется MultiDiGraph: направленный мультиграф допускает разные рёбра между одной парой узлов. У узла хранятся тип и подпись, у ребра предикат и документы-источники.

Одинаковая выбранная тройка не повторяется. Структура хранения сама не извлекает отношения и не подтверждает их истинность.

Источник: §2.1 с.7–10 (PDF27–30); notebook, яч.24.

Схема ограничивает допустимые связи

Предикат	Русский смысл	Число сигнатур
Located_in	расположен в	5
Occurs_on	относится к дате	5
Found_on	обнаружен на	4
Transmits	переносит	2
Dispersed_by	распространяется через	2
Causes	вызывает болезнь	1
Affects	поражает растение	1

Итого: 7 предикатов, 20 сигнатур.

Сигнатура: предикат + тип субъекта + тип объекта.

Примеры сигнатур:

Pest → Causes → Disease

Disease → Affects → Plant

Vector → Transmits → Pest

Pest → Located_in → Location

Описание PestCLEF на Kaggle перечисляет 18 сочетаний. Ещё два поддержаны эталоном: Dissemination_pathway → Located_in → Location и → Occurs_on → Date.

По 20 сочетаниям проверяются кандидаты и вставка рёбер. Проверочная схема задаёт допустимость типов, а не вывод новых фактов. Подходящие типы могут сопровождать неверную связь.

Источник: notebook, яч.17,24; §3.1.2 с.27/PDF47.

От текста к графу: шесть шагов

Текст документа

↓

1. CRF + словарь: упоминания и типы

▾

2. Нормализация: концепты и формы

▾

3. Схема + 154 признака: кандидаты

▾

4. LightGBM + отбор: выбранные тройки

▾

5. MultiDiGraph: типы и источники

▾

6. CSV для Kaggle; GraphML для хранения

NER распознаёт упоминания; объединение связывает формы; извлечение отношений оценивает пары концептов.

Графовый слой повторно проверяет сигнатуры, убирает дубликаты, сохраняет документы-источники и поддерживает запросы.

Множество троек до и после графового слоя совпало. Отдельный прирост F1 от него не измерен; новые факты по правилам не выводятся.

Если отношение потеряно до кандидатов, граф его не восстановит. Если оно выбрано ошибочно, sources поможет проверить исходный текст.

Источник: notebook, яч.11–24,31,33,39.

CRF и словарь находят упоминания

NER распознаёт упоминания именованных сущностей: тип и символьные границы в тексте.

CRF, условное случайное поле, предсказывает последовательность BIO-меток: B начинает упоминание, I продолжает, O обозначает прочий текст.

Признаки: написание и регистр, форма слова, префиксы/суффиксы, признаки даты/места, соседние токены и обучающий словарь. Контекст помогает выбрать совместимую последовательность меток.

Источник: notebook, яч.11,13; §6.2.2 с.107/PDF127.

Два применения словаря:

1. Признак CRF: поиск известных последовательностей слева направо, с приоритетом самого длинного совпадения.

2. После CRF: добавление надёжных знакомых форм отдельным словарём.

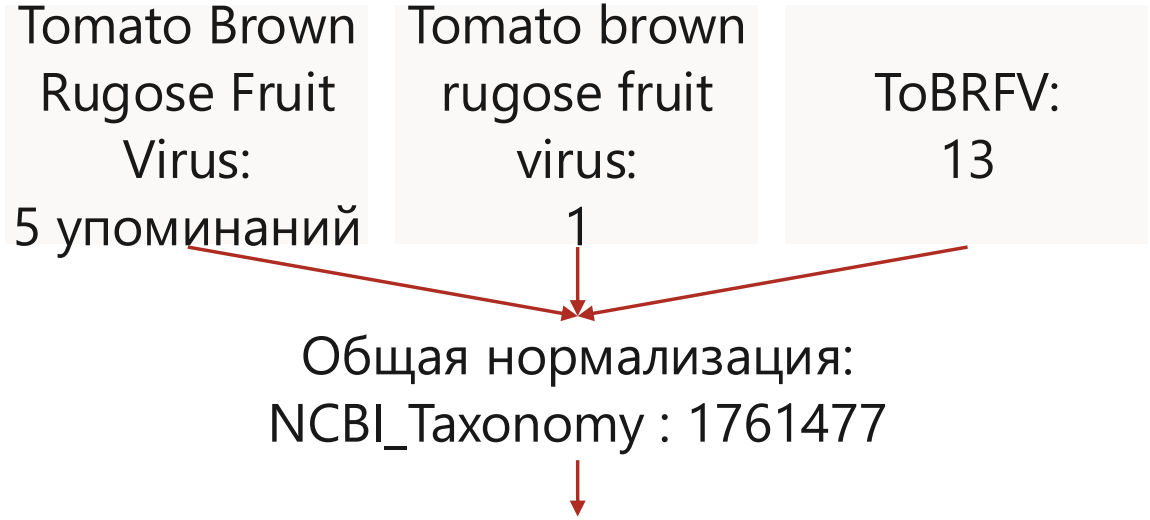
При объединении CRF имеет приоритет. Словарные добавления идут от длинных к коротким и не пересекают занятые границы.

Словари строятся из разрешённой обучающей разметки. Новая форма или неверная граница может привести к пропуску сущности и отношений.

Источник: notebook, яч.15,26.

Идентичность отделена от подписи

Документ 104650: один концепт Pest



Выбирается самая частая форма; при равенстве первая по позиции. Сокращение наследует идентификатор раскрытой формы.

Источник: walkthrough.json, concepts[0].

Ключ концепта: тип и пара resource/reference из обучающей нормализации. Одинаковые номера разных ресурсов не равны.

Без ссылки используется нормализованная форма. Шаблон «полное название (сокращение)» связывает варианты; одинаковые строки разных типов остаются разными концептами.

Но id экспортируемого графа проще: тип + нормализованная каноническая строка. Внешняя идентичность полностью не сохраняется. Возможны раздельные алиасы и слитые омонимы; полного междокументного разрешения нет.

Источник: notebook, яч.17,24,37; §3.2 с.35–37/PDF55–57.

154 признака описывают кандидата

Кандидат: одна направленная тройка концептов (субъект, предикат, объект), ещё не выбранная в ответ.

Для каждой из 20 сигнатур перебираются все пары концептов подходящих типов. Каждая допустимая тройка получает один вектор.

Итого 154; индикаторы слов бинарные.

Источник: candidates, notebook, яч.19,22.

Группа признаков	Число
Базовые: типы, частоты, позиции, расстояния	30
Слова между упоминаниями	62
Слова во внешнем контексте	62

Из всех пар упоминаний выбирается ближайшая по начальным позициям. Слова берутся из первых 300 символов между ними и 60 символов снаружи. Расстояния по предложениям/абзацам отдельно минимизируются по всем парам.

pair_prior считает обучающие отношения с той же парой форм и предикатом. Из обучающих признаков вычитается вклад документа. Это счётчик, не вероятность или правило.

LightGBM — бинарный классификатор,250 раундов бустинга деревьев. При обучении y=1, если предикат и нормализованные формы концов совпадают с эталонной связью; иначе y=0. Выход p оценивает совпадение кандидата с разметкой; отдельный отбор определяет включение связи.

Источник: notebook, яч.17,19,22,29.

От оценки кандидата к набору связей

Кандидаты сортируются по оценке p.
Для первых k кандидатов:

$$G = \max\left(1, \frac{\sum p}{\rho}\right)$$

$$\hat{F}_1(k) = \frac{2\sum_{\text{top-k}} p}{k + G}$$

G оценивает число эталонных связей; Σp суммирует оценки всех кандидатов документа. Выбирается k с наибольшей F^1.

rho = 0.7 изменяет G и размер выбранного набора. Это не порог отдельного ребра.

Источник: notebook, select, яч.21.

empty_t=0.3 проверяет документ: если максимальная оценка ниже 0.3, ответ пуст.

Поштучного удаления всех рёбер ниже 0.3 нет: такой кандидат может войти в выбранную верхнюю часть списка, если документ прошёл проверку.

Процедура приближённая: неизвестный эталон не используется. Калибровка оценок как вероятности биологической истинности не измерена.

rho и empty_t сохранены при сравнении и не подбирались на внешних проверочных прогнозах.

Источник: notebook, яч.21,29; quality.json, settings.

Пример 104650: текст и упоминания

Фрагмент текста [84,265):

“Tomato brown rugose fruit virus (ToBRFV; genus, Tobamovirus, family, Virgaviridae) was first reported in 2015 infecting tomatoes grown under protected cropping in the Jordan Valley.”

Форма → тип → [начало,конец)

Полное название → Pest → [84,115)

ToBRFV → Pest → [117,123)

tomatoes → Plant → [204,212)

Jordan Valley → Location → [251,264)

Смещения считаются с нуля; конец не включён.

Источник:104650.txt; walkthrough.json.

Фрагмент сообщает о возбудителе на tomatoes в Jordan Valley; это чтение текста, а не исправление прогноза.

Весь документ:38 упоминаний →11 концептов →36 кандидатов →15 троек. Полные формы и ToBRFV составили один концепт из 19 упоминаний.

Показан сохранённый прогноз внешнего фолда 2, третьего при нумерации с нуля. Документ и его текстовая группа исключены из обучения прогнозирующей модели. Эталон нужен только для сравнения.

Источник: notebook, яч.51; walkthrough.json.

Пример 104650: оценки и результат

Кандидат	Оценка	Выбран
ToBRFV → Found_on → tomatoes	0.931085	да
ToBRFV → Located_in → Jordan Valley	0.916850	да

Для первого кандидата:

subject_mentions=19; object_mentions=5

same_sentence=1; same_paragraph=1

pair_prior=5

Это значения входных признаков и выход модели. Они не являются измерением вклада отдельных признаков или калиброванной вероятностью истинности.

Источник: walkthrough.json, top_candidates[0:2].

Граф: Pest:ToBRFV → Found_on → Plant:tomatoes; источник 104650.

Две записи выбранного JSON:

{"predicate":"Found_on","subject":"ToBRFV","object":"tomatoes"}

{"predicate":"Located_in","subject":"ToBRFV","object":"Jordan Valley"}

Граф содержит все 15 выбранных троек. CSV сохраняет только predicate, subject, object; типы и sources остаются графовыми атрибутами.

Пример показывает прохождение цепочки, но не отсутствие ошибок документа.

Источник: walkthrough.json, graph_json; notebook, яч.24,31.

Проверка отделяет обучение от оценки

165 документов →164 текстовые группы

5 внешних групповых фолдов, seed 0

Внешнее обучение:

5 внутренних фолдов: один прогнозируется, остальные 4 обучают NER

OOF-упоминания

Признаки

Обучение LightGBM

Внешняя проверка:

Только текст

NER, обученный на внешнем обучении

Признаки

Отношения

Оценка по эталону

Группа: одинаковый текст после сворачивания пробелов.

Для каждого: обучение отдельно от проверки.

Словари, нормализации и частоты не видят внешнюю проверку.

Текстовая группа объединяет одинаковые тексты. Фолд — отложенная часть разбиения, содержащая несколько групп. OOF: документ и группа не участвовали в обучении прогнозирующей модели.

Дополнительно: словарный признак CRF исключает группу документа; Priors вычитает его собственные частоты. Это не ещё пять CRF.

Карта нормализаций отношений использует всё внешнее обучение, не отдельные внутренние OOF-карты.

rho/empty_t фиксированы заранее;5 финальных seed относятся к test.

Источник: notebook, яч.9,13,17,22,26,29,33.

Качество: точность, полнота и F1

TP: совпавшая эталонная связь
FP: прогноз без совпадения
FN: эталонная связь без совпадения

Точность (precision) $$P = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FP}}$$

Полнота (recall) $$R = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FN}}$$

F1 $$F_1 = \frac{2\mathrm{TP}}{2\mathrm{TP} + \mathrm{FP} + \mathrm{FN}}$$

Macro F1: среднее F1 по документам, каждый имеет одинаковый вес.

Micro F1: F1 из суммарных TP,FP,FN; документы с большим числом связей дают больше счётчиков.

Источник: notebook, яч.8,43.

Локальный scorer сверяет тройки с наборами эквивалентных форм эталона. Для предикатов игнорируются регистр, пробелы и подчёркивания; для форм регистр и пробелы.

Повторы прогнозов удаляются, учитывается первый совпавший эталон; оптимального взаимно-однозначного сопоставления нет. Оба графа пусты: F1=1; пустой эталон и непустой прогноз:0.

Эквивалентность evaluator Kaggle не подтверждена. Совпадение с разметкой не устанавливает полноту всех биологических знаний.

Источник: notebook, яч.8; §7.1–2 с.119–121/PDF139–141.

Сопоставимое сравнение двух вариантов

Прежняя группировка (legacy)

Macro F1:0.527168

Micro precision:0.583541

Micro recall:0.461084

Micro F1:0.515135

При ссылке на полное название сокращение могло остаться с ключом раскрытой строки, а полная форма — с ключом нормализации. Один объект мог попасть в разные группы.

Общие условия: внешние фолды, NER-прогнозы, scorer,250 раундов,seed 0,rho0.7,empty_t0.3.

Исторический F1≈0.5428 получен зависимым протоколом и здесь не сопоставим.

Исправленная группировка (fixed)

Macro F1:0.532901

Micro precision:0.583594

Micro recall:0.459113

Micro F1:0.513923

Сначала ищется нормализация раскрытого полного названия, затем исходной формы; иначе используется раскрытая строка. Это даёт формам общий ключ, если известна ссылка.

Macro:+0.005732;micro:−0.001211.

Сравнение относится к группировке в одном независимом протоколе, не к эффекту графового контейнера.

Источник: quality.json, comparison; notebook, cluster.

Kaggle и воспроизводимый результат

Оценка отправки	Значение
Public	0.57890
Private	0.58085
Исторический public	0.38757
Разница public	+0.19133

Подтверждение: снимок пользователя.

Статус: Complete (after deadline).

Точный прежний CSV и прежний private неизвестны. Официальное место в зачёте не заявляется.

Public/private относятся к разным частям test. Эти числа нельзя напрямую сравнивать с локальной CV и приписывать весь прирост одному изменению.

Источник: kaggle-validation.json.

CSV побайтово совпадает с подтверждённым файлом; оценки применяются при совпадении SHA256.

31 кодовая ячейка прошла новые ядра:

холодный запуск:1086.95 с

с кэшем:49.22 с

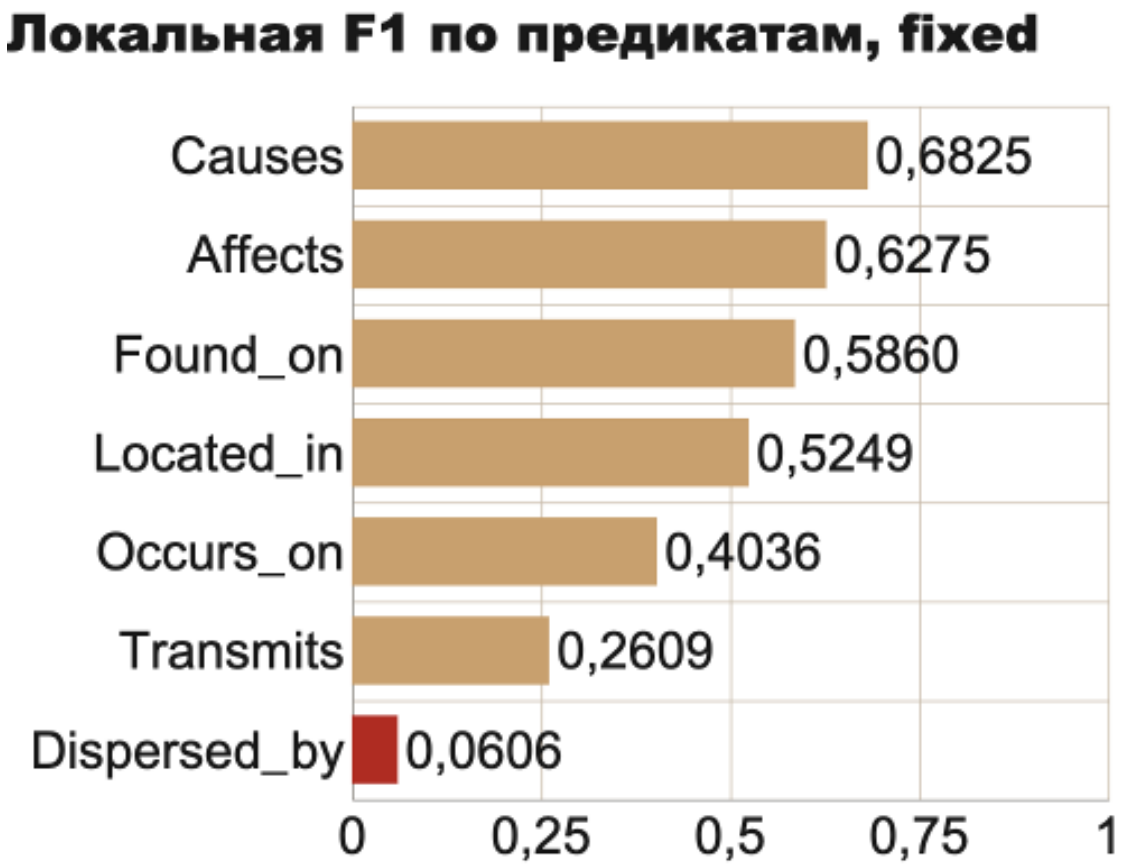
из fdd:47.95 с

CSV и локальные метрики совпали. Сохранены CRF, словари, нормализации, частоты, пять LightGBM. Для test оценка кандидата — среднее выходов этих пяти моделей.

predict_document(doc_id,text,bundle) принимает новый текст без эталона. Проверены загрузка моделей и GraphML.

Источник: final-checks.json; inference-smoke.json.

Главные потери: кандидаты и Dispersed_by



Шкала 0–1; показатели посчитаны из TP,FP,FN каждого предиката.

Кандидаты покрыли 1373/2030 эталонных связей,67.6%; отсутствующую пару отбор не восстановит.

Dispersed_by: TP 2,FP 16,FN 46; F1=0.0606. Прежний вариант:0.0923, здесь ухудшение.

104650: “Seed transmission of ToBRFV…” Эталон ToBRFV → Dispersed_by → Seed есть, кандидата нет.

Причина ранней потери не установлена: возможны NER, нормализация или генерация пары. Примеры не измеряют частоты причин.

Источник: quality.json; error-cases.json[7].

Документные графы и общий граф

Предсказанная выборка → значение

Test-документы	82
Документные тройки	975
Пустые документные графы	5
Узлы общего графа	437
Разные рёбра общего графа	737
Слабые компоненты общего графа	8
Крупнейшая компонента, узлов	415

Слабая компонента: связность без учёта направления. Узлы создаются при вставке выбранной связи, поэтому изолированных узлов 0. Это не означает, что текст не содержал иных сущностей.

Источник: analysis.json, passport.

Повтор тройки в разных документах увеличивает 975, но объединяется в одном ребре. Разница 238 означает повторные появления.

Id узла: тип + нормализованная каноническая строка. Из 737 рёбер 609 имеют один источник,128 несколько; максимум 12 документов.

sources указывает происхождение, а не истинность. Единого doc_id общего графа нет: документы перечислены у узлов и рёбер. В GraphML списки записаны JSON-строками.

Это состав предсказаний, не их точность.

Источник: notebook, яч.24,37,39,48.

Запрос 1: места для Xylella

Шаблон: (Pest:xylella, Located_in, ?place)
?place обозначает искомый узел Location.

Место	Документы ребра
BARI	100506, 103887 115980, 116010
Monopoli	102276, 102892 102894, 97985
Netherlands	102892
Polignano a Mare	105574, 99733

Всего 47 разных Location. Здесь показаны 4; полный ответ сохранён в analysis.json, queries.pest_locations.results.

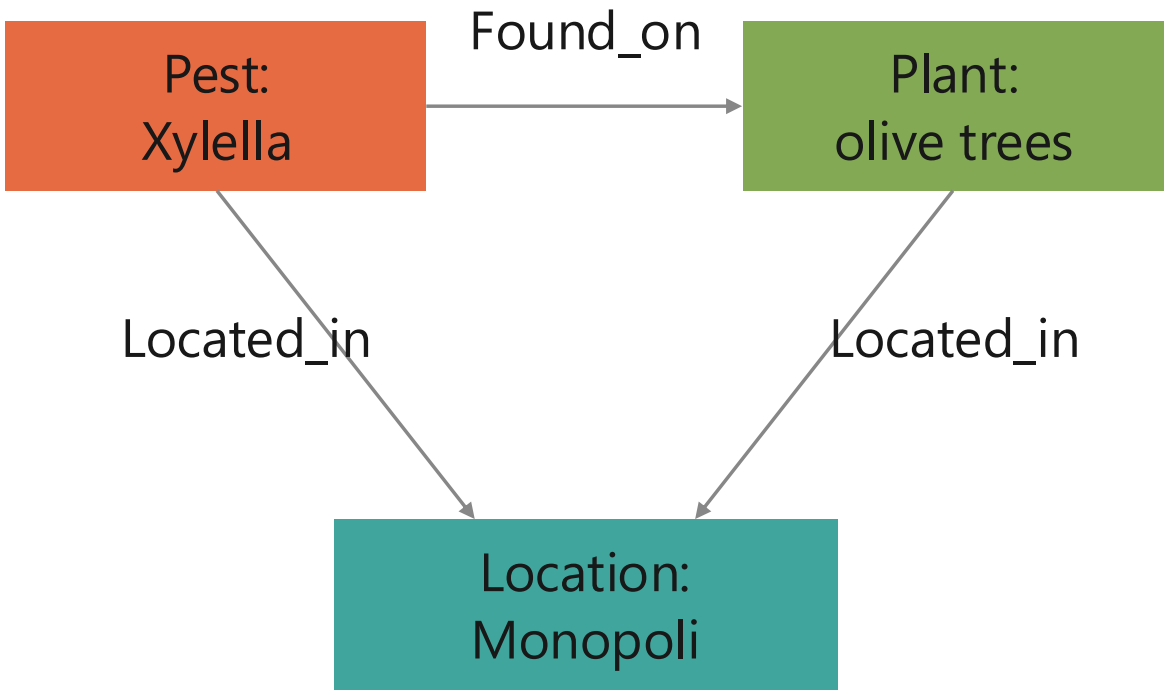
Xylella выбран по максимуму разных Location по Located_in; при равенстве по id. Это правило выбора узла, не рейтинг распространённости.

Шаблон сопоставляет переменную с существующими рёбрами. Здесь работают функции NetworkX; SPARQL/Cypher не реализованы.

47 означает число строковых узлов, не подтверждённых очагов. Возможны неоднозначные формы и ошибки извлечения. sources каждого ребра позволяет проверить его документный контекст.

Источник: analysis.json; §2.2.1 с.13–15/PDF33–35.

Фрагмент графа документа 97985



Три узла, три направленных ребра. У всех sources=[97985].

Цвет обозначает тип: Pest, Plant или Location. Это фрагмент, а не весь граф документа.

Источник: подготовленный 97985.graphml.

doc_id97985; фрагмент[275,331):

“There are 30 olive trees infected by Xylella in Monopoli”

Текст сообщает о заражённых Xylella оливковых деревьях в Monopoli. Он позволяет прочитать связь возбудителя с растением и местом.

sources возвращает к документу; не удостоверяет истинность автоматически. Проверен этот фрагмент, не все связи корпуса. Числа общего тестового графа и оценки CSV относятся к полной выборке исходного CSV, а не к размеру иллюстрации.

Источник:97985.txt; §3.3 с.40/PDF60.

Запрос 2: вредители для Bananas

Шаблон: (?pest, Found_on, Plant:bananas)
?pest ограничен типом Pest, Vector не считается.

Полный ответ: подпись Pest → документы

FocR1	117415
FocTR4	117415
Fusarium oxysporum cubense Race 1	118038
R. solanacearum	99632
Ralstonia solanacearum Race 2	99632
Tropical Race 4	118038

Всего 6 узлов. Названия сохранены дословно; таксономическое объединение не выполнялось.

Источник: analysis.json, queries.plant_pests.

Bananas выбран по максимуму входящих Pest с Found_on; при равенстве по id. Возвращаются все 6 записей с источниками.

Разные формы могут обозначать один объект, но сходство строк не разрешает их автоматически объединять. Xylella и Xylella fastidiosa имеют разные id; таксономическое равенство не установлено.

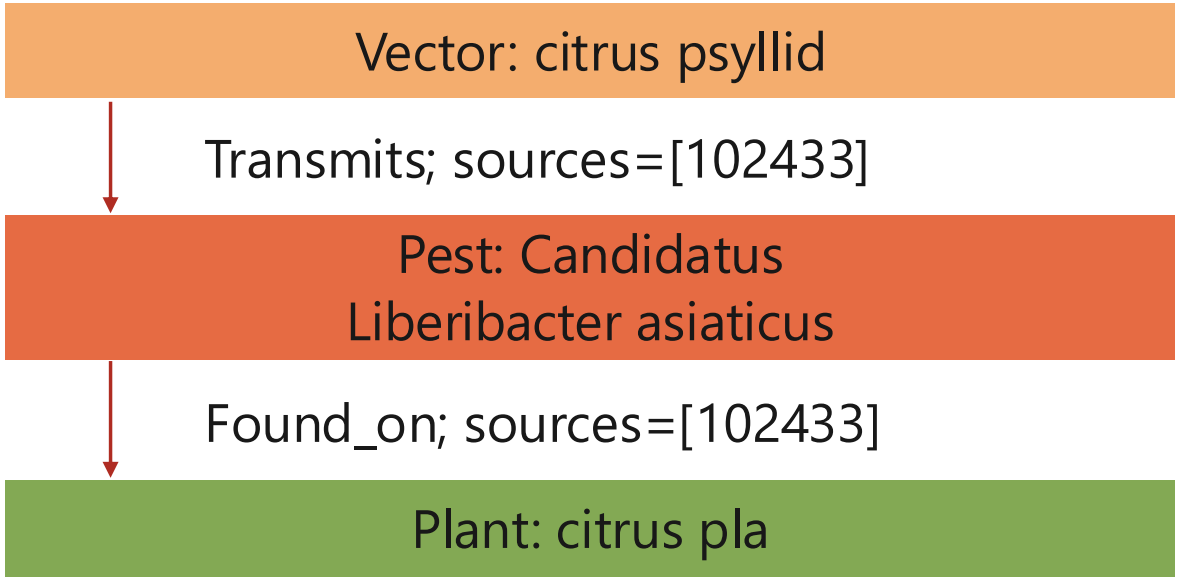
Шум границ:104657 содержит Location «from East Asia» и Date «first time». Тип не гарантирует чистую нормализацию.

Полное междокументное связывание не реализовано.

Источник: analysis.json, identity_examples.

Запрос 3: путь из двух отношений

Шаблон:
Vector → Transmits → Pest → Found_on → Plant
Реальный фрагмент:



Обе связи предсказаны в документе 102433. Подпись «citrus pla» усечена в исходном результате и сохранена без исправления.

Источник: analysis.json, common_document[0].

Путь соединяет два отношения по общему Pest, как соединение записей в БД.

Из 29 путей 10 имеют общий документ: пересечение sources рёбер непусто. У 19 источники не пересекаются.

Даже общий документ не доказывает одно событие. Рёбра предсказаны; строковая идентичность узла может быть неоднозначной.

Запрос не создаёт Vector → Plant и не подтверждает новый факт. Дедукция потребовала бы отдельных правил и посылок; она не реализована.

Источник: §2.2.1 с.13–15/PDF33–35; гл.4 с.47/PDF67.

Что сделано и как применять результат

Воспроизводимая цепочка: CRF и словари → концепты → кандидаты → LightGBM и отбор → граф → CSV/GraphML.

Независимая локальная macro F1=0.532901. Конкретный CSV: Kaggle public 0.57890, private 0.58085, поздняя отправка.

Граф хранит типы, проверяет 20 сигнатур, убирает повторы и сохраняет источники. Три запроса демонстрируют выборку и соединение отношений.

Источник: notebook; quality.json; analysis.json; kaggle-validation.json.

Для ответа сначала читаем рёбра и sources, затем проверяем фрагмент текста и идентичность узлов. Записанный путь сам не является новым фактом.

Ограничения: потеря связей до кандидатов, слабый Dispersed_by, ошибки границ и ограниченное междокументное объединение. Типовая валидность не гарантирует смысловую правильность.

Вывод новых фактов, полная онтология и распределённая серверная платформа не реализованы. Книга помогает различать эти уровни; текущие измерения подтверждают только показанную цепочку и её результаты.

300 ЛЕТ СПбГУ

Авторы проекта

Кубякин Никита

Зайнуллин Мансур

Аникин Роман

СПбГУ ·4-й курс ·23.Б16-пу

Базы данных и распределённая цифровая платформа